Tugas 1: Audit Data dan Exploratory Data Analysis

203012520032 - Seagata Ade Pratama Barus

A. Audit Kualitas Data

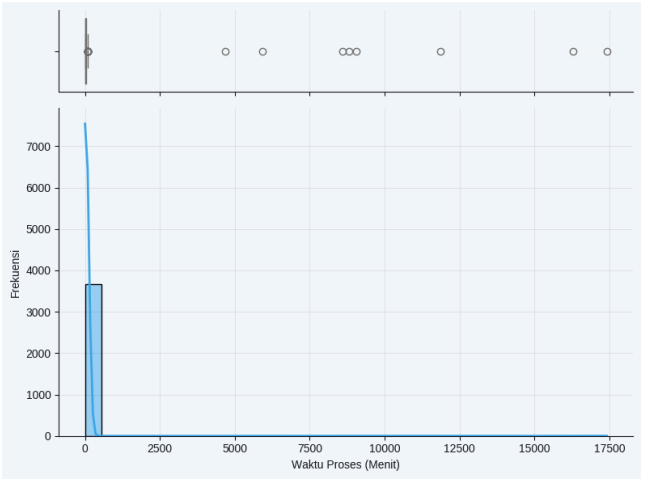
Dataset terdiri dari 3.765 baris × 12 kolom; berisi transaksi dari sistem operasional suatu toko retail. Audit dilakukan dari kolom ke kolom, kemudian pemeriksaan keseluruhan kolom. Urutan pengerjaan dirasa penting karena beberapa masalah menyebabkan masalah lain, sehingga keputusan perbaikan diurutkan berdasarkan ketergantungan. Extra note, tidak ada data yang di hapus karena cukup bodoh untuk menghapus data log dari proses penjualan.

Kolom terdampak	Jenis masalah	Bukti	Dampak	Keputusan dan alasan
kanal	Tidak konsisten	11 variasi penulisan untuk 2 kategori: kapitalisasi (ONLINE, offline), spasi di awal (" Online"), sinonim (Daring, Luring), dan on-line	228 baris (6,1%)	Whitespace ditrim, lalu dipetakan ke Online/Offline, datanya valid, hanya penulisannya yang kacau
tanggal	Tidak konsisten (format)	Tanggal mempunya 2 format, ISO8601 & DD/MM/YYYY	Seluruh kolom	Diparse format='mixed', dicast ke DD/MM/YYYY (format Indonesia)
harga_satuan & total_transaksi	Satuan berbeda antar kelompok	Median total Bandung = 234 dibandingkan ~265.000 pada cabang lain	481 baris (12,8%)	Kolom moneter Bandung × 1.000 (asumsi: 11.5 berarti 11.500).
id_transaksi	Duplikat	39 id ganda identik; 27 id isi berbeda	66 baris (1,8%)	Beda ID, sama data: entri terakhir dipertahankan (asumsi: koreksi salah ketik); duplikat persis: drop_duplicates()
jumlah_unit & total_transaksi	Mustahil (logika)	14 baris unit=0 tetapi total>0	14 baris (0,4%)	Dihitung kembali dengan formula Unit = Total / (Harga × (1−Diskon/100)); verifikasi: semua hasil bilangan bulat
total_transaksi	Inkonsisten antar kolom	89 baris menyimpang >2% dari unit×harga×(1−diskon)	89 baris (2,4%)	Dihitung ulang, bisa saja salah catat.
waktu_proses_menit	Mustahil (negatif)	20 baris negatif, min −22,5 menit	20 baris (0,5%)	Tanda minus dihapus (salah ketik tanda), karena nilai absolutnya dalam rentang normal
rating_pelanggan	Hilang + mustahil	136 kosong; 148 baris bernilai 99 (di luar skala 1–5)	284 baris (7,5%)	setelah melakukan ANOVA untuk rating, diputuskan untuk di-average kan tergantung kategori, jika di-avg secara normal akan mengacaukan distribusi per kategori, more on note

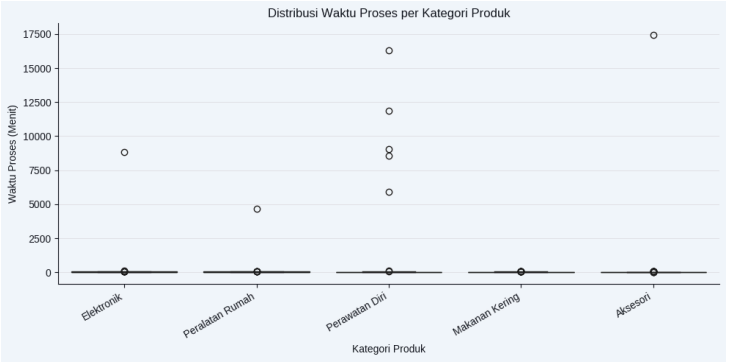
Note: Karena rating antar channel sangat berpengaruh ($p < 0.001$) maka analisis objective ke-2 akan cukup berpengaruh, namun hasilnya setelah diuji cobakan, mirip saja.

B. Temuan Hubungan Antar Variabel

B1 Bagaimana sebaran waktu proses pesanan, dan apakah sebaran itu sama untuk semua kelompok transaksi?

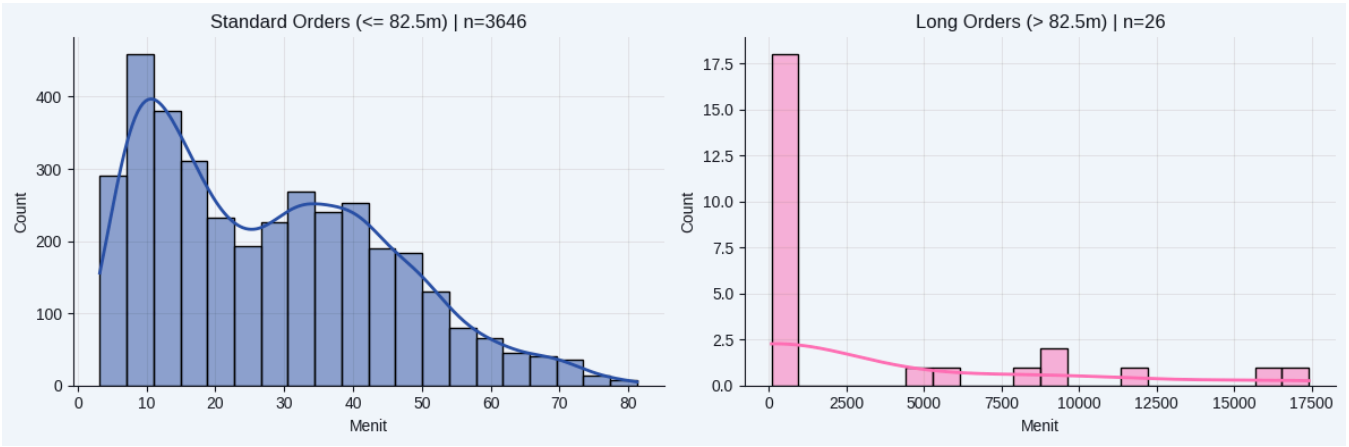


Gambar 1: boxplot+histogram waktu proses

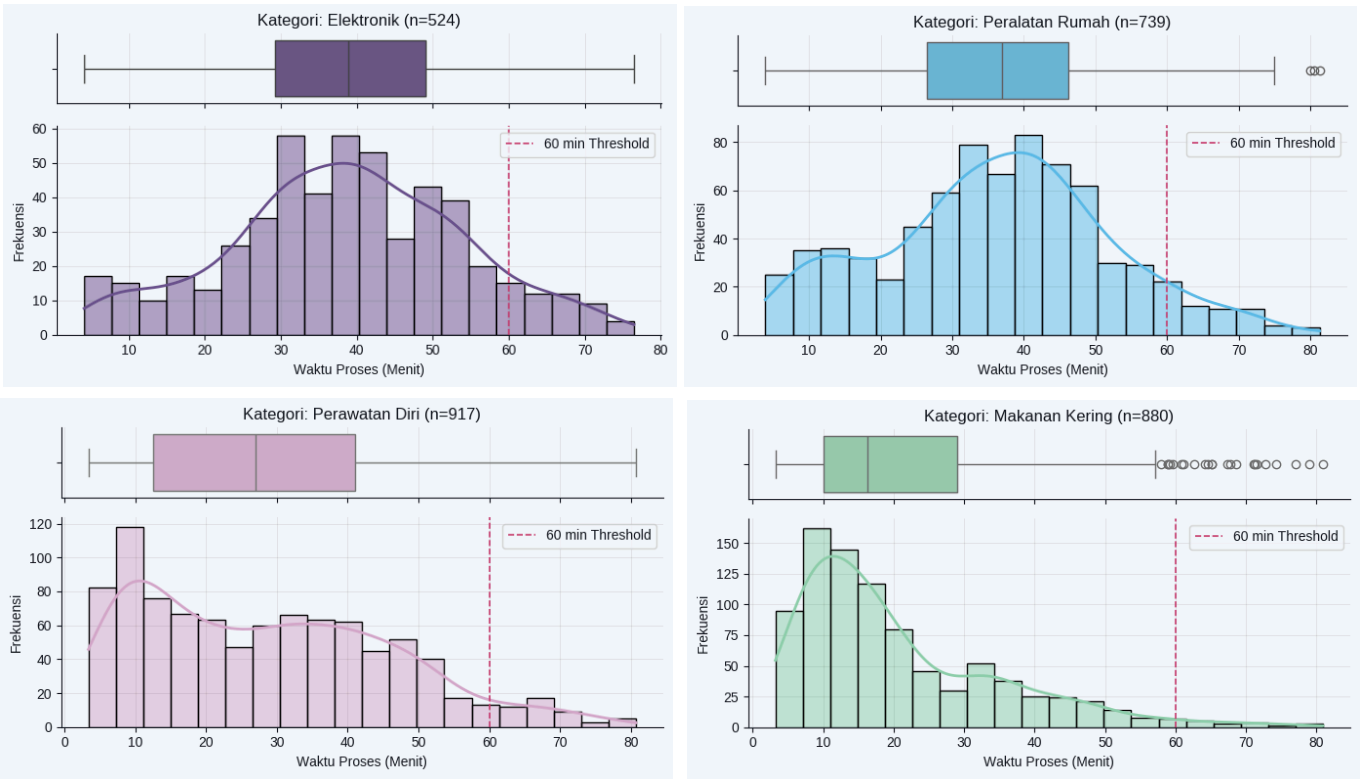


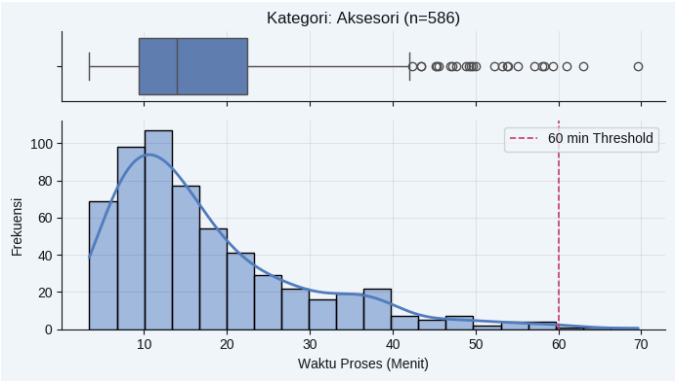
Gambar 2: boxplot per kategori

Dikarenakan data dengan waktu yang melebihi upper bound (82,5 menit) masih disimpan maka visualisasinya tidak akan begitu baik, maka dibuat 2 plot barr



Gambar 3: boxplot+histogram waktu proses secara terpisah



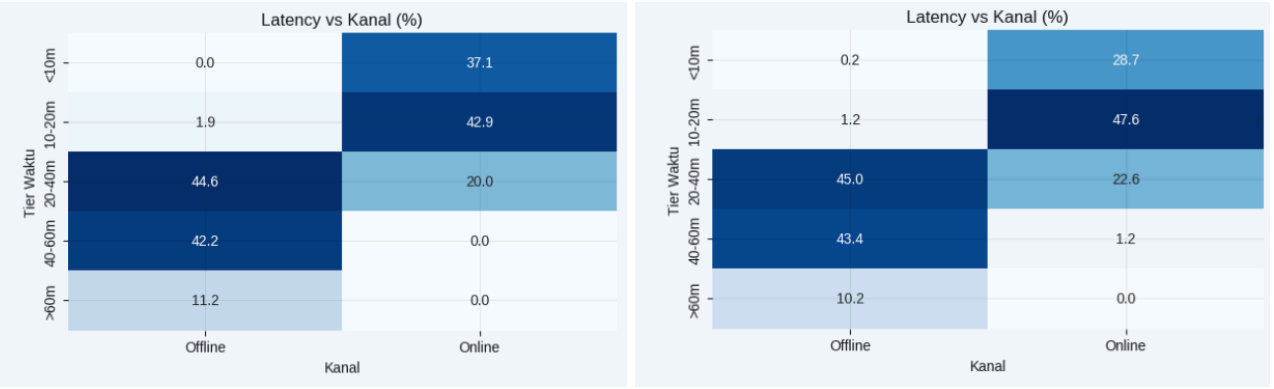


Gambar 4: persebaran per kategori tanpa data diluar upper bound

Dikarenakan, maksimum dari laporan adalah 4 lembar, untuk analisis lebih detail mengenai keterhubungan antar waktu proses dan kolom lainnya dapat dilihat detail pada python notebook. Data sangat right-skewed: median 25,8 menit (Q1 12,7, Q3 40,6) tetapi maksimum 17.411,8; batas Tukey 82,5 menit; 99,3% transaksi < 60 menit. Menggabungkan tiap kategori menyembunyikan perbedaan nyata antar kelompok:

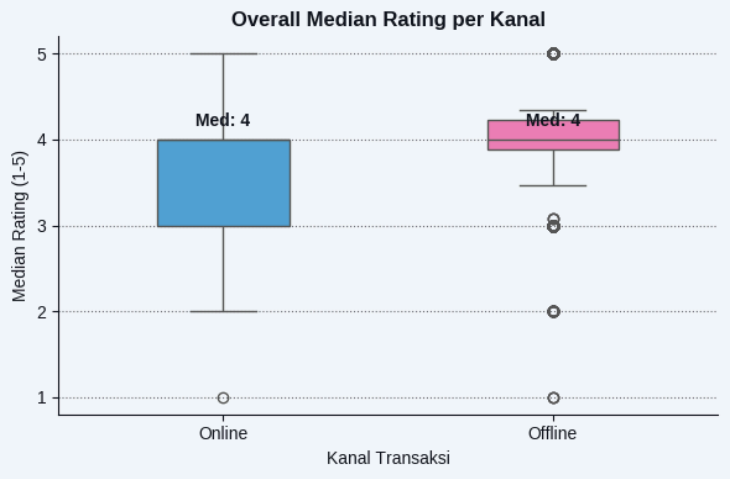
Kategori	**Median (menit)**	**% > 60 menit**
Elektronik	39,1	9,6%
Peralatan Rumah	37,1	7,7%
Perawatan Diri	27,1	6,5%
Makanan Kering	16,4	2,4%
Aksesori	13,9	0,7%

Jawaban: Tidak sama. Kategori barang fisik berukuran e.g. Elektronik & Peralatan Rumah konsisten ~3× lebih lambat dari Aksesori. Mayoritas transaksi selesai dengan cepat (<10 menit) secara keseluruhan tetapi bukan cerita lengkap, dan juga item offline lebih lama diproses dibandingkan online, dst (cek ipynb).

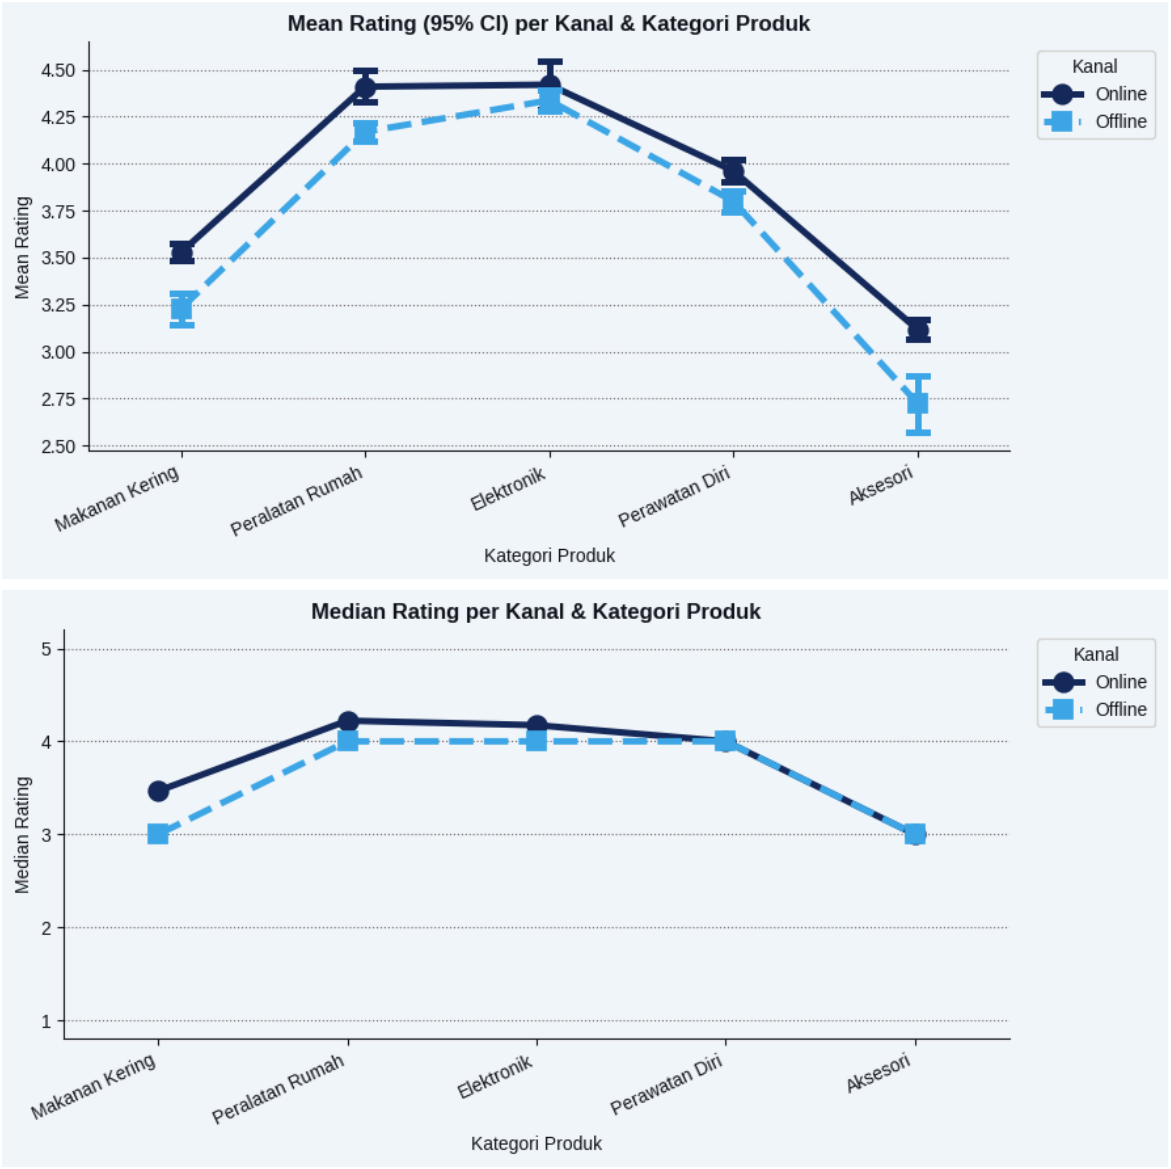


Gambar 4: pembagian % lama waktu proses(menit) untuk kategori elektronika (L) & peralatan rumah tangga (R)

B2 Apakah rating pelanggan berbeda antara kanal transaksi? Periksa jawaban Anda sekali lagi setelah memperhitungkan kategori produk — apakah kesimpulannya tetap sama?



Gambar 5: plot median rating per kanal



Gambar 6: pointplot mean & median rating per kategori

Jawaban: Ya, rating berbeda antara kanal. Gap terbesar di kategori low-value item e.g. Aksesori, Makanan Kering. Hal tersebut tidak begitu besar hilang pada Elektronik. **Karena tidak diminta untuk mengambil kesimpulan bisnis dan hanya analisis maka tidak akan saya berikan**

kanal	n	mean	std	median
Offline	1772	3.96	0.75	4.0
Online	1900	3.63	0.76	4.0